

基于多模态融合的城市交通事件检测方法研究

张明远¹ · 李思涵² · 王建国³ · 陈晓东¹

(¹. 滨海大学计算机科学与工程学院, 滨海 315000; ². 华东理工大学自动化系, 上海 200237; ³. 中科院自动化研究所, 北京 100190)

摘要: 针对城市复杂交通场景下单一传感器难以全面感知多类型交通事件的瓶颈问题, 提出一种基于摄像头、雷达和地磁三源数据深度融合的交通事件检测方法。该方法采用时空对齐模块实现异构数据的统一表征, 引入基于注意力机制的多模态特征融合网络提取跨模态互补特征, 并通过时序因果推理模型区分正常交通波动与真实异常事件。在滨海市实测数据集 (含12,480条标注样本, 覆盖拥堵、事故、抛洒物、逆行、违规变道五类事件) 上的实验表明, 本方法的平均检测准确率达到96.7%, 平均误报率为2.3%, 较基线方法分别提升8.4个百分点和降低5.1个百分点。该方法已集成至滨海市智慧交通管控平台并在86个路口投入试运行, 实时处理延迟控制在200毫秒以内, 具备良好的工程化应用前景。

关键词: 多模态融合; 交通事件检测; 注意力机制; 深度学习; 智慧城市

1 引言

随着城市化进程的加速推进和机动车保有量的持续增长, 城市交通系统面临的压力日益严峻。据公安部交通管理局发布的最新统计数据显示, 截至2025年底全国机动车保有量已达4.48亿辆, 其中汽车保有量3.42亿辆, 驾驶人数量达5.26亿人。交通拥堵、交通事故、交通违法等问题不仅严重影响城市居民的出行效率和生活质量, 还造成了巨大的经济损失和环境负担。研究表明, 交通拥堵导致我国主要城市年均通勤时间损失超过每人每年89小时, 由此产生的燃油浪费和碳排放增量分别约占城市交通总能耗的18%和总排放量的12%。在此背景下, 利用先进的信息感知技术和人工智能算法构建智能化的交通事件检测系统, 成为提升城市交通管理水平核心手段之一。传统的交通事件检测方法主要依赖固定地磁线圈或超声波探测器, 这类方法虽然成本较低且技术成熟, 但存在检测类型有限 (仅能检测占有率变化)、布设维护困难、对路面破坏较大等固有缺陷。近年来, 随着计算机视觉技术的快速发展, 基于摄像头的视频分析方法逐渐成为主流研究方向。卷积神经网络 (CNN) 在目标检测、行为识别等任务上取得了突破性进展, YOLO系列、Faster R-CNN、SSD等算法在交通场景下的车辆检测、行人识别、车道线分割等任务中均表现出优异的性能。然而, 单一视觉传感器在实际应用中仍面临诸多挑战: (a) 光照条件剧烈变化 (夜间、逆光、雨雾) 导致图像质量下降; (b) 摄像头视角受限存在盲区, 无法检测被遮挡的目标; (c) 纯视觉方法难以获取精确的速度和距离信息, 影响事件严重程度的判断。因此, 学术界和工业界开始探索多传感器融合的技术路线, 试图通过整合摄像头、毫米波雷达、激光雷达、地磁等多种感知源的信息来弥补单一传感器的不足。本文聚焦于摄像头—雷达—地磁三种最具性价比的传感器组合, 研究面向城市路口场景的多模态交通事件检测方法。主要贡献包括: (1) 设计了基于时空配准的对齐模块, 将采样频率从1Hz (地磁) 到30 fps (视频) 的三种异步数据统一映射到统一的时空坐标系; (2) 提出了跨模态注意力融合网络, 自适应地为不同模态分配权重, 在正常天气下侧重视觉特征而在恶劣条件下增强雷达和地磁信号的贡献; (3) 构建了包含五种常见交通类型的标注数据集并进行了全面的消融实验验证。

2 相关工作

2.1 基于视频的交通事件检测视频分析方法是目前交通事件检测领域的研究热点。早期工作主要依赖手工设计的特征如光流直方图 (HOF)、梯度方向直方图 (HOG) 和Gabor滤波器等结合SVM或随机森林分类器进行识别。深度学习方法兴起后, 两阶段检测器 (Faster R-CNN系列) 和单阶段检测器 (YOLO系列、SSD、RetinaNet等) 相继被应用于交通目标检测任务。Zhang等人[1]提出了一种基于3D CNN的时空网络, 能够同时捕捉视频帧内的空间特征和帧间的时间动态, 在UCF-Sports数据集上取得了当时的最佳效果。Li等人[2]将Transformer架构引入交通场景理解, 通过自注意力机制建模全局上下文关系, 显著提升了小目标和遮挡目标的检测精度。近期的研究趋势是结合大语言模型的语义推理能力, 实现从“检测目标”到“理解事件”的跨越式进步。

2.2 多模态融合方

法多模态学习旨在整合来自不同感官渠道的信息以获得更鲁棒和更全面的表征。根据融合发生的层次不同，现有方法可分为三类：早期融合（数据层融合）直接拼接原始输入或浅层特征，计算简单但忽略了模态间的语义差异；晚期融合（决策层融合）各自独立处理后合并输出结果，保留了模态特异性但缺乏中间交互；中期融合（特征层融合）在网络的中间层进行交互平衡了上述两种策略的优劣，是当前主流选择。文献[3]提出的Multimodal Transformer使用交叉注意力机制让每个模态查询其他模态的特征表示，在音频-视觉分类任务上取得了显著提升。文献[4]则研究了模态缺失情况下的鲁棒融合策略，通过训练时随机丢弃某些模态来模拟实际部署中的传感器故障场景。

2.3 交通事件检测数据集公开数据集方面，UA-DETRAC数据集提供了超过10小时的高质量交通视频和82个车辆类别的标注；BDD100K数据集包含了10万段驾驶视频和多种天气条件下的标注；国内的中科院交通事件数据集（CASIA-TED）收录了来自15个城市的3万余条事件样本。然而这些数据集大多只包含视频模态，缺少同步的多传感器数据，限制了多模态方法的研究和对比评估。本文构建的数据集填补了这一空白。

3 方法

3.1 问题形式化定义设城市路口感知系统在时刻 t 收集到的多模态观测数据记为 $X_t = \{V_t, R_t, M_t\}$ ，其中 $V_t \in \mathbb{R}^{H \times W \times 3}$ 表示摄像头捕获的RGB图像帧， $R_t \in \mathbb{R}^{N_r \times d_r}$ 表示雷达点云数据（ N_r 为目标数量， d_r 为每目标的特征维度包括距离、方位角、径向速度、反射截面积）， $M_t \in \mathbb{R}^{N_m \times d_m}$ 表示地磁传感器阵列读数（ N_m 为车道线圈数量， d_m 为每线圈的频率域特征）。目标是学习一个判别函数 $f_\theta: X \rightarrow Y$ 将观测序列映射到事件标签空间 $Y = \{\text{正常, 拥堵, 事故, 抛洒物, 逆行, 违规变道}\}$ ，同时输出事件发生的时间戳 τ 和置信度分数 $p \in [0, 1]$ 。优化目标为最小化带权交叉熵损失：
$$L_{\text{total}} = \sum_t [\alpha \cdot \text{CE}(y_t, \hat{y}_t^{\text{vis}}) + \beta \cdot \text{CE}(y_t, \hat{y}_t^{\text{rad}}) + \gamma \cdot \text{CE}(y_t, \hat{y}_t^{\text{mag}})] + \lambda \|\theta\|^2$$
其中 $\alpha + \beta + \gamma = 1$ 为模态平衡系数， λ 为正则化强度。

3.2 时空对齐模块由于三种传感器的采样频率差异巨大（视频30Hz、雷达10Hz、地磁1Hz），首先需要进行时间维度的对齐。我们采用线性插值法将低频数据上采样至30Hz基准频率，然后通过卡尔曼滤波平滑高频数据的抖动噪声。空间维度上，通过预先标定的外参矩阵将雷达点云和地磁感应区域投影到图像坐标系中，建立像素级的位置对应关系。标定过程使用OpenCV的solvePnP算法求解，平均重投影误差控制在1.5个像素以内。

3.3 跨模态注意力融合网络融合网络由三个编码分支和一个融合中心组成。每个编码分支根据输入模态特性采用不同的骨干架构：视觉分支使用在COCO数据集上预训练的ResNet-50提取CNN特征后接位置编码注入空间先验；雷达分支使用PointNet++架构处理非结构化的点云数据；地磁分支使用一维卷积网络处理时序波形。三个分支的输出特征首先通过一个共享的全连接层投影到统一的 $d=512$ 维嵌入空间，然后送入多头交叉注意力（MHA）模块。MHA的核心计算为： $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k})V$ 其中 Q 来自当前模态的特征， K 和 V 来自另外两个模态的特征集合。这种设计使得每个模态能够主动查询其他模态中的互补信息——例如当图像因夜晚过暗而丢失细节时，网络可以自动增加对雷达距离测量和地磁占有率变化的关注权重。

4 实验

4.1 数据集与实验设置实验数据采集自滨海市滨海新区CBD核心区的86个信号控制路口，采集周期为2025年6月至12月共六个月。原始数据包括约2,400小时的1080P@30fps视频流、同步的毫米波雷达扫描数据和地磁频率响应曲线。经专业标注团队审核筛选后，最终获得12,480条有效标注样本，各类别分布为：正常状态8,720条（69.9%）、拥堵事件1,872条（15.0%）、交通事故事件624条（5.0%）、抛洒物事件498条（4.0%）、逆行事件436条（3.5%）、违规变道330条（2.6%）。数据集按8:1:1划分为训练集、验证集和测试集，划分时保持类别比例一致。

4.2 对比实验结果我们将所提方法与六种基线方法进行了对比：（A）纯视觉3D-CNN方法；（B）视觉+雷达后期融合；（C）视觉+地磁后期融合；（D）三模态简单拼接；（E）Multimodal Transformer基线；（F）本文方法（完整版）。评价指标选用精确率（Precision）、召回率（Recall）和F1分数。实验结果表明，本文方法（F）在所有五类事件上的平均F1值达到0.967，较次优方法（E）提升了4.2个百分点。尤其在光照不良时段（18:00-次日06:00），本文方法的性能优势更为明显——F1值差距扩大到7.8个百分点，验证了跨模态注意力机制在补偿视觉缺陷方面的有效性。

4.3 消融实验为验证各模块的贡献，我们依次移除时空对齐模块（w/o Align）、交叉注意力模块（w/o CrossAttn）和时序因果推理模块（w/o Causal）。结果显示，移除任一模块都

会导致性能下降，其中交叉注意力模块的影响最为显著（F1下降5.1%），说明模态间的自适应融合是整个系统的关键所在。

5 结论

本文提出了一种面向城市路口场景的多模态交通事件检测方法，通过融合摄像头、雷达和地磁三种传感器的互补信息，实现了对多种交通事件的高精度实时检测。在真实城市环境下的实测结果表明，本方法在检测准确率和误报控制方面均优于现有的单模态方法和简单的多模态拼接方法。未来的研究方向包括：（1）扩展至更多传感器类型如激光雷达和热成像；（2）探索无监督或半监督学习范式以降低标注成本；（3）研究边缘端部署方案以满足实时性要求更高的车路协同应用场景。

参考文献

- [1] Zhang Y, Chen W, Wang L, et al. Spatio-temporal traffic event detection using 3D convolutional neural networks[J]. IEEE Transactions on Intelligent Transportation Systems, 2024, 25(3): 2345-2358.
- [2] Li S, Zhao Q, Liu H, et al. TransTraffic: Transformer-based traffic scene understanding with global context modeling[C]. Proceedings of CVPR 2025: 12456-12466.
- [3] Huang Y, Zhuang F, Wu F, et al. Multimodal transformer with cross-modal attention for audio-visual recognition[J]. Knowledge-Based Systems, 2023, 267: 110345.
- [4] Wang X, Zhang L, Chen T. Robust multimodal fusion under missing modality scenarios[J]. Pattern Recognition, 2024, 148: 110102.
- [5] 交通部公路科学研究院. 城市道路交通事件检测技术规范（JT/T 1389-2021）[S]. 北京: 人民交通出版社, 2021.